

研究日志

概述

- 研究目的
 - 了解西安交通大学医学领域的热点，以及相关的研究者，为进入实验室学习做准备
 - 锻炼数据处理的能力，包括从pubmed中下载并处理元数据、用python清洗数据、VOSviewer可视化数据结果等能力
- 研究主要成果
 - 分析得到热点关键词，并大致看出研究趋势
- 研究流程及方法
 - 从pubmed上获取近5年西安交通大学的论文数据
 - 导入到zotero中进行初步的数据预处理
 - 从zotero中导出“脏”数据，导入到python进行数据清洗
 - 利用python清洗数据的同时，分析部分内容，具体如下
 - 高产作者前十列表
 - 作者合作关系分析
 - 论文数量的时序分析
 - 热点词汇的列表
 - 热点词汇的时序分析
 - 热点词汇的共现分析
 - 最后利用VOSviewer生成可视化图表
- 研究主要失败点
 - 由于名字清洗算法出现问题，没有得到有价值的研究者信息
- 自认为的精彩点
 - [VOSviewer分析及结论](#)
 - [热点词汇的共现网络分析的结论](#)
 - [热点词汇的时序分析](#)

目录

- [研究方法前期设计](#)
- [同步到Github版本管理](#)
- [数据获取](#)
- [数据清洗](#)
- [Python 分析可视化与结果分析](#)
- [VOSviewer分析](#)

研究方法前期设计

使用OpenRouter的多种模型询问详细研究指导

prompt:

我是医学生，开学大二，为了丰富自己的科研经历，准备找教授，班主任告诉我要先了解教授信息以及自己的兴趣点，所以我准备利用pubmed中的元数据，使用文献计量学的方法对本学校（西安交通大学）的作者及其研究方向做一个梳理，请给具体的详细的指导和建议。

我使用的工具是zotero和VOSviewer，还有python脚本辅助

使用的模型列表

```
gemini-2.5-flash
gemini-2.5-pro
claude-3.7-sonnet
claude-3.7-sonnet;thinking
claude-opus-4
claude-opus-4.1
claude-sonnet-4
```

最后确定是gemini两个模型的版本

```
gemini-2.5-flash
gemini-2.5-pro
```

使用的工具、软件

- Pubmed
- Obsidian
- VSCode
- Zotero
- VOSviewer
- Python

Pubmed

- 数据来源

Obsidian

- 开源笔记软件，主要用来读文献，记录笔记、日志等
- 由于安装了AI插件，需要API KEY，上传到github上会暴露隐私信息，所以没有上传obsidian的配置文件

VSCode

- 主要用来git管理，和python编译

Zotero

- 文献数据汇总，管理原数据，并导出为合适的数据类型

VOSviewer

- 文献计量学的可视化软件，用来进行文献计量学分析和可视化操作

Python

- 编程语言，用来数据清洗

同步到Github版本管理

- 使用vscode插件快速创建代码仓库，并上传文件
- 跳过上传原始数据等涉及到隐私或者版权问题的文件
- obsidian由于安装了AI插件，需要API KEY，上传到github上会暴露隐私信息，所以没有上传obsidian的配置文件

数据获取

从 pubmed 上获取数据

由于近五年数据过于庞大，因此分别检索每一年的内容，并下载元数据

下载2025年数据

```
"Xi'an Jiaotong University"[Affiliation] OR "First Affiliated Hospital of Xi'an Jiaotong University"[Affiliation] OR "Second Affiliated Hospital of Xi'an Jiaotong University"[Affiliation] AND 2025[pdat]
```

下载2024年数据

```
"Xi'an Jiaotong University"[Affiliation] OR "First Affiliated Hospital of Xi'an Jiaotong University"[Affiliation] OR "Second Affiliated Hospital of Xi'an Jiaotong University"[Affiliation] AND 2024[pdat]
```

下载2023年数据

```
"Xi'an Jiaotong University"[Affiliation] OR "First Affiliated Hospital of Xi'an Jiaotong University"[Affiliation] OR "Second Affiliated Hospital of
```

```
Xi'an Jiaotong University"[Affiliation] AND 2023[pdat]
```

下载2022年数据

```
"Xi'an Jiaotong University"[Affiliation] OR "First Affiliated Hospital of  
Xi'an Jiaotong University"[Affiliation] OR "Second Affiliated Hospital of  
Xi'an Jiaotong University"[Affiliation] AND 2022[pdat]
```

下载2021年数据

```
"Xi'an Jiaotong University"[Affiliation] OR "First Affiliated Hospital of  
Xi'an Jiaotong University"[Affiliation] OR "Second Affiliated Hospital of  
Xi'an Jiaotong University"[Affiliation] AND 2021[pdat]
```

原数据放在data/raw中

导入到 zotero 中

将数据导入到zotero中方便管理

- 重新建立一个新的文献库 MEDscience-map-of-XJTU
- 导入这五年的pubmed数据
- 2025年数据正确导入
- 2024年数据导入时发现有5篇文章已被撤稿，无法导入，具体信息如下
- 导入2023年数据，也有被撤稿的文章
- 导入2022年数据，也有被撤稿的文章
- 导入2021年数据，也有被撤稿的文章

数据清洗

见notebook中的文件

Python分析可视化与结果分析

高产作者前十列表

```
--- 最高产作者 Top 20 ---  
authors_list  
Zhang Y 2707  
Wang Y 2434  
Li Y 2044  
Wang J 1911  
Wang X 1847
```

```
Zhang J 1660
Li J 1653
Liu Y 1532
Li X 1521
Zhang X 1384
Zhang L 1293
Wang Z 1183
Liu J 1167
Zhao Y 1080
Wang H 1078
Liu X 1052
Li Z 1040
Chen Y 1022
Zhang H 1008
Li H 973
```

数据处理中，姓名的处理规则如下：


```
'Jin, Xuting' -> 'Jin X'
' Wang, Hua ' -> 'Wang H'
'Lina Zhou'   -> 'Zhou L'
'Elsevier'    -> 'Elsevier'
```

结论

由于姓名处理规则不能很好的辨别中国人的名字，系统辨别的重名的可能性非常大，因此没有任何参考价值

作者合作关系分析


Core Collaboration Network (Top 50 Authors, Min. 3 Collaborations)



结论

对于找教授用处不大，而且图像复杂不易观看，仅能知道几位热点作者

论文数量的时序分析



结论

- 2021年论文数量最少，可能是因为疫情
- 2022年论文数量突然“报复性增长”，猜测是因为实验室已经正常运转，并且疫情提供了许多研究课题
- 2025年，因为还未到年底，论文数量还有望回升

热点词汇的列表（Top50）

---（过滤后）真正的研究热点关键词 Top 50 ---

Gene Expression Regulation, Neoplastic	381
COVID-19	309
SARS-CoV-2	248
Algorithms	214
Cell Proliferation/genetics	208
Reactive Oxygen Species/metabolism	196
Biomarkers	184
Tumor Microenvironment	173
*MicroRNAs/genetics/metabolism	171
Polymorphism, Single Nucleotide	169
Immunotherapy	161
Mendelian randomization	154
Gene Expression Profiling	147
Genome-Wide Association Study	141
*Air Pollutants/analysis	141
Mutation	134
*COVID-19	133
Oxidative Stress	133
Breast cancer	131

Cell Movement	130
Hepatocellular carcinoma	130
Molecular Docking Simulation	129
*MicroRNAs/genetics	128
Signal Transduction/drug effects	126
Genetic Predisposition to Disease	121
Cell Differentiation	117
Cytokines/metabolism	117
Magnetic Resonance Imaging	114
Cell Movement/genetics	111
Oxidative stress	109
Machine learning	108
Depression	107
Cell Proliferation/drug effects	106
Particulate Matter/analysis	102
Apoptosis/drug effects	102
Machine Learning	101
Autophagy	98
Proto-Oncogene Proteins c-akt/metabolism	98
Environmental Monitoring	97
Apoptosis/genetics	95
*Neural Networks, Computer	94
*Deep Learning	93
*Algorithms	92
breast cancer	91
Biomarkers/blood	91
Neoplasm Staging	90
Transcriptome	90
Biomarkers, Tumor/genetics	89
*Machine Learning	89
Neural Networks, Computer	89
Name: count, dtype: int64	

结论

1. 癌症的分子机制与治疗：


- **深度机制：** Gene Expression Regulation, Neoplastic , Tumor Microenvironment, Mutation , Proto-Oncogene Proteins c-akt/metabolism, Reactive Oxygen Species/metabolism , Oxidative Stress , Autophagy , Cell Proliferation/genetics , Cell Proliferation/drug effects , Apoptosis/genetics , Apoptosis/drug effects , Cell Movement , Cell

Movement/genetics , Cell Differentiation , Signal Transduction/drug effects , Cytokines/metabolism 。


- **治疗前沿:** Immunotherapy , Molecular Docking Simulation (药物发现)。
- **临床应用与诊断:** Biomarkers , Biomarkers/blood , Biomarkers , Tumor/genetics , Neoplasm Staging 。
- **具体癌种:** Breast cancer , Hepatocellular carcinoma 。

2. **COVID-19与病毒学:** COVID-19 , SARS-CoV-2 。这仍然是一个高频且重要的研究领域。
3. **AI/机器学习在生命科学的应用:** Algorithms , Machine Learning , Neural Networks , Computer , Deep Learning 。这表明AI/ML已不再是单纯的工具，而是作为一种核心方法学，深入渗透到生物医学的各个层面。
4. **组学与遗传学前沿:** *MicroRNAs/genetics/metabolism , Polymorphism , Single Nucleotide , Mendelian randomization , Gene Expression Profiling , Genome-Wide Association Study , Genetic Predisposition to Disease , Transcriptome 。这些关键词揭示了从基因组、转录组层面，通过统计遗传学方法，深入探究疾病易感性、发生机制和诊断标志物的趋势。
5. **环境健康与毒理学:** *Air Pollutants/analysis , Particulate Matter/analysis , Environmental Monitoring 。表明环境因素与人类健康关系的研究日益受到重视。
6. **神经科学/精神疾病:** Depression 。提示精神疾病是一个重要的研究方向。
7. **影像学技术:** Magnetic Resonance Imaging 。作为重要的诊断和研究工具。

热点词汇的时序分析



这个图或许更能分清楚



结论

- 1. Gene Expression Regulation, Neoplastic (肿瘤基因表达调控)**

分析： 这个话题整体呈现出**波动上升的趋势，并在高位保持热度**。2021年到2022年有显著增长（74到94），表明其热度在初期得到提升。2023年的下降（到40）可能是一个异常值，或者代表了该年度某个特定细分研究方向的减弱，但2024年（90）和2025年（83）的数据强劲反弹并保持在高位，回到甚至超过了2022年的水平。这表明**肿瘤领域中关于基因表达调控的研究是持续且稳定的热点**。
- 2. COVID-19 (新冠肺炎)**

分析： COVID-19 的趋势非常明显，呈现出**持续且快速的下降**。从2021年的高点102，一路下降到2025年的29。这反映了全球疫情从大流行急性期逐步进入常态化管理阶段，以及疫苗和治疗方法取得进展的现实。媒体和社会关注度普遍下降，科研投入也随之调整。虽然研究仍在继续，但焦点已从大规模的疫情应对转向其他领域。
- 3. SARS-CoV-2 (SARS-冠状病毒2)**

分析： 与 COVID-19 趋势高度一致，SARS-CoV-2（病毒本身）的研究热度也呈现**持续下降**。从2021年的92下降到2025年的30。这再次印证了疫情研究的总体趋势。虽然热度下降，但病毒学本身的基础研究和变异株监测仍将是必要的，只是不再是“超高热度”的话题。
- Algorithms (算法)**

分析： Algorithms 话题呈现出**显著的、持续的上升趋势**。从2021年的24迅速增长到2025年的63，尽管中间在2023年有小幅回调（37），但随后强劲反弹，并在2025年达到历史新高。这强烈表明**算法相关研究在科学领域的应用越来越广泛和深入**。随着数据量的


爆炸式增长，对高效、准确算法的需求也随之增加。这是一个强劲的上升趋势，预示着未来科研中计算方法和工具的重要性只会增而不会减。

- **5. Cell Proliferation/genetics (细胞增殖/遗传学)**

分析： 这个话题呈现出**明显的高开低走趋势**。2021年到2022年有了显著的峰值增长（38到78），表明在2022年达到一个相对高点。但随后，从2022年到2025年呈现出明显的持续下降趋势（78到14）。

热点词汇的共现分析

Core Thematic Network (Filtered, Top 50 Keywords, Min. 5 Co-occurrences)



结论

一、疫情相关研究：

- **COVID-19 & SARS-CoV-2 (122 / 78 / 53):** 这是最高共现频率。表明对COVID-19的研究仍然紧密围绕其病原体SARS-CoV-2展开。*COVID-19 与 COVID-19 本身的高度共现(72

*COVID-19 COVID-19 53) 再次确认了数据清洗中将它们合并的必要性。

- **与其他主题的关联逐渐减弱但存在:** Molecular Docking Simulation 与 SARS-CoV-2 (11), COVID-19 (6) 都还有共现, 表明新药研发或机制研究仍在持续。*Air Pollutants/analysis 与 SARS-CoV-2 (10) / COVID-19 (9/6) 以及 Environmental Monitoring 与 SARS-CoV-2 (9) / COVID-19 (6) 有共现, 这提示了疫情与环境因素的潜在联系 (如空气传播、环境载量等), 虽然权重不高, 但值得关注。Depression 与 COVID-19 (8)提示了疫情对心理健康的影响。

二、肿瘤学及其分子机制:

这是最复杂且最丰富的共现网络, 显示了肿瘤研究的深度和广度。

- **核心耦合 (高权重):**
 - **Gene Expression Regulation, Neoplastic & Cell Proliferation/genetics (103):** 肿瘤基因表达调控和细胞增殖/遗传学是肿瘤研究的核心! 理解基因如何调控细胞增殖在肿瘤发生发展中的作用是基石。
 - **Gene Expression Regulation, Neoplastic 和相关主题的共现非常广泛:**
 - 与 Cell Movement/genetics (61): 基因调控如何影响肿瘤细胞的运动和侵袭。
 - 与 Cell Movement (50): 细胞运动在肿瘤转移中的关键作用。
 - 与 *MicroRNAs/genetics/metabolism (42): miRNA作为重要的基因表达调控因子, 在肿瘤中的作用是热点。
 - 与 Gene Expression Profiling (43): 基因表达谱分析是研究基因表达调控的重要技术。
- **肿瘤微环境与免疫治疗:**
 - **Immunotherapy & Tumor Microenvironment (34):** 免疫疗法是癌症治疗的革命性进展, 而肿瘤微环境是影响免疫治疗效果的关键, 两者紧密相关。
 - Gene Expression Regulation, Neoplastic 与 Tumor Microenvironment (12): 肿瘤基因调控也影响微环境。
- **关键分子与通路:**
 - Proto-Oncogene Proteins c-akt/metabolism (98) 与 Gene Expression Regulation, Neoplastic (13): c-akt作为重要的原癌基因通路, 在肿瘤基因调控中扮演角色。
 - Reactive Oxygen Species/metabolism 与 Oxidative Stress (21/20), 与 Cytokines/metabolism (12), 与 Apoptosis/drug effects (18), 与 Signal Transduction/drug effects (9): 活性氧、氧化应激是肿瘤发生发展及治疗敏感性的重要因素, 并与细胞信号通路、细胞凋亡、细胞因子、免疫治疗等广泛相关。
- **表观遗传与非编码RNA:**
 - *MicroRNAs/genetics/metabolism 与 Cell Proliferation/genetics (55), Cell Movement/genetics (30): miRNA不仅是基因表达调控的关键, 也直接影响肿瘤细胞的增殖和运动。
 - Apoptosis/genetics 与 *MicroRNAs/genetics/metabolism (23): miRNA在细胞凋亡的遗传调控中发挥作用。

- **特定癌种:**

- Hepatocellular carcinoma (肝细胞癌) 与 Gene Expression Regulation, Neoplastic (25), Cell Proliferation/genetics (16), Cell Movement/genetics (12), Tumor Microenvironment (5): 肝癌作为特定肿瘤, 其研究也遵循肿瘤学的主线。
- Breast cancer (乳腺癌) 与 Gene Expression Regulation, Neoplastic (9), Tumor Microenvironment (6), Neoplasm Staging (5), Biomarkers, Tumor/genetics (109), Cell Proliferation/genetics (6): 乳腺癌研究深入到基因调控、微环境、生物标志物等多个层面。

- **生物标志物与诊断:**

- Biomarkers, Tumor/genetics 与 Gene Expression Regulation, Neoplastic (21), Mutation (12), Transcriptome (7), Gene Expression Profiling (16), *MicroRNAs/genetics (10): 肿瘤生物标志物的研究高度依赖于基因表达、突变、转录组和基因表达谱等方面的发现。

三、遗传学、组学与大数据方法:

- **Mendelian randomization & Genome-Wide Association Study (42), Polymorphism, Single Nucleotide & Genome-Wide Association Study (58), Genetic Predisposition to Disease & Polymorphism, Single Nucleotide (55), Genetic Predisposition to Disease & Genome-Wide Association Study (29):** 这是一个紧密的三角关系! GWAS (全基因组关联研究) 用于发现与疾病相关的SNP (单核苷酸多态性), 而孟德尔随机化法则利用SNP作为工具变量来推断因果关系, 这三者共同构成了**复杂疾病遗传易感性研究的核心方法论和内容**。
- **Transcriptome & Gene Expression Profiling (30):** 转录组学和基因表达谱分析是研究基因表达水平变化的重要技术, 两者是相辅相成的。
- Gene Expression Profiling 与 Genome-Wide Association Study (8), Transcriptome 与 Genome-Wide Association Study (6): 揭示了基因组学和转录组学在疾病研究中的结合。


四、计算科学与AI/ML的渗透:


- **Algorithms & *Deep Learning (26), Neural Networks, Computer & Algorithms (25), Algorithms & *Neural Networks, Computer (25), Algorithms & Machine Learning (22), Machine Learning & *Machine Learning (39):** 这组关键词的高共现揭示了**AI/ML方法论的层级关系和广泛应用**。Algorithms 是最顶层概念, 而 Machine Learning 是 Algorithms 的一个重要分支, Deep Learning 和 Neural Networks, Computer 又是 Machine Learning 的重要实现技术。这再次印证了数字工具在科研中的核心地位。
- 虽然直接与生物学主题的共现权重相对较低 (例如 Gene Expression Regulation, Neoplastic 与 Machine learning (6), *Machine Learning (5)), 但考虑到其作为通用工具的属性, 其渗透的广度远超这些数字。

五、环境健康：

- ***Air Pollutants/analysis & Particulate Matter/analysis (87)**: 这是环境健康领域最强的共现，表明空气污染物研究高度聚焦于颗粒物。
- ***Air Pollutants/analysis & Environmental Monitoring (70), Particulate Matter/analysis & Environmental Monitoring (49)**: 表明环境监测是研究空气污染物和颗粒物的重要手段。这揭示了一个完整的环境健康研究链条：**监测-分析-特定污染物（颗粒物）**。

VOSviewer分析





结论

西安交通大学医学领域的研究热点是

- 疫情相关研究
- 肿瘤学和分子机制相关
- 遗传学、组学与大数据
- 新兴的计算机算法，机器学习，深度学习等AI交叉领域